

1D706 統計推測特論

1. 記述統計

April 13, 2026

数理環境論 Room 742

Email: ZHOU YI <zhouy@people.kobe-u.ac.jp>

クォーター

- ・ 第 1-7 回：授業
- ・ 第 8 回：最終レポート（成績評価）

授業の概要（内容は調整される場合がある）

- ・ Q1：統計基礎知識
- ・ Q2：統計検定
- ・ Q3：多変量推測
- ・ Q4：回帰モデル

この講義の中心：様々な方法が医学研究でどのように使われているか？

- ・ Fundamentals of Biostatistics (Bernard Rosner)
- ・ 生物統計学入門—ハーバード大学講義テキスト
(Pagano,Marcello/Gauvreau,Kimberlee 【著】 / 竹内 正弘 【監訳】)

統計学 statistics

- ・ 数値データの収集・整理・分析

生物統計学 biostatistics

- ・ 生物学や健康学の分野に焦点を当てる

データ分析の最初のステップは、手元のデータを簡潔に記述すること

例 1.1 ビタミン A

一部の研究者は、ビタミン A の摂取ががん予防に効果があると提唱している。**この仮説を検証するために**、食事に関する質問票を用いた調査が考えられる。

対象は、入院中の**がん患者（症例群）** 200 名と、年齢・性別をマッチングさせた**対照群** 200 名である。対照群は、がんとは無関係の疾患で同時期に入院している患者とする。

このように収集されたビタミン A 摂取量に関するデータを、どのように活用すべきだろうか。

PICO（または PICOS）：統計分析（臨床研究）の設計において、研究の問い（リサーチクエスション）を明確にするためのフレームワーク


PICOS を用いることで、研究の**目的**が構造化され、論文検索や**解析手法**の選定がスムーズになる

- ・ Patient / Population（どのような対象か）：入院中のがん患者 200 名（症例群）
- ・ Intervention / Exposure（介入/曝露、何を行うか）：ビタミン A 摂取量
- ・ Comparison（何と比較するか）：非がん患者（対照群）
- ・ Outcomes（アウトカム、何が改善・変化するか）：ビタミン A 摂取量とがん発症との関連
- ・ Study design（どのような研究デザインか）：観察研究（症例対照研究）

仮説を検証する前に、まずは**症例群と対照群におけるビタミンA摂取量を記述する必要がある**

棒グラフ (bar graphs)

1-5 倍の RDA 範囲 (x 軸) において、対照群 (下) が症例群 (上) よりも多くのビタミン A を摂取 (y 軸) している



例 1.2 喫煙

医学研究では、受動喫煙（自らは喫煙しないが、他者の煙がある環境で生活・就労すること）が肺機能に悪影響を及ぼす可能性が長らく疑われてきた。


1980 年、US の研究グループは、受動喫煙者の肺機能が、煙のない環境で働く非喫煙者と比較して有意に低いことを示す研究結果を発表した。さらに、その証拠を補強するため、著者らは**受動喫煙者と喫煙禁止環境で働く非喫煙者**の職場における一酸化炭素（CO）濃度を測定し、その濃度が一日の中でどのように推移するかを調査した。

PICOS?

- ・ P（対象）：受動喫煙者
- ・ I/E（曝露）：受動喫煙
- ・ C（比較）：喫煙環境に曝露されていない非喫煙者
- ・ O（アウトカム）：肺機能、職場環境の CO 濃度の変化
- ・ S（研究デザイン）：観察研究（横断的調査報告）

散布図 (scatter plot)

2つの作業環境におけるCO濃度 (y 軸) は、早朝の時点 (x 軸) ではほぼ同等であるが、日中にかけて大きく乖離し、終業時の午後7時に向けて再び収束していくことが明確に示されている



優れたグラフや数値表示のガイドライン

- ・ 自己完結性 (Self-contained) の確保
 - ・ 読み手が本文を一行も読まなくても、その図表が「何を (対象)」 「どのような (変数)」 示しているのかが分かる必要がある。
 - ・ タイトル・脚注: 図の下 (図注) や表の上 (表題) に、具体的な内容を記述する。
 - ・ 凡例 (Legend) : 複数のグループがある場合は、必ず色やパターンの意味を明示する。
- ・ 明確なラベル付けと定義
 - ・ 軸ラベル: 縦軸と横軸には必ず変数名と単位 (例: 濃度 [ppm]、肺機能 [L]) を記載する。
 - ・ 統計量の明記: 「エラーバー」を表示する場合、それが標準偏差 (SD) なのか、標準誤差 (SE) なのか、あるいは 95% 信頼区間 (95% CI) なのかを必ず注釈に入れる。
- ・ 適切なデータ量の選定
 - ・ 棒グラフのグループ数: 一般に、一つのグラフで比較するグループは 5-7 個程度までが認識しやすい。
 - ・ 表の構成: 表は精密な数値を伝えるのに適しているが、行や列が多すぎる場合は、重要なデータに太字を用いるなどの強調や、サマリー表への集約が有効だ。

データの標本 $x_1, \dots, x_n$ を考える。

この標本が母集団 P から抽出されたと仮定すると、標本を用いて母集団 P に関するどのような推論や結論を導き出せるだろうか。

データを要約する際に役立つ指標の一つに、標本の中心、すなわち「中央付近」の値を示すものがある。

このような指標は、**位置の尺度** (Measures of Location) と呼ばれる。

この標本における位置の尺度の一つは、算術平均（一般的に「平均」と呼ばれる）である。

定義 1.1 算術平均

算術平均とは、すべての観測値の合計を観測値の数で割ったものである。

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

一般に「平均 (average)」と呼ばれる。

算術平均（平均 (mean)、標本平均 (sample mean)）は、通常 $\bar{x}$ で表される。

例 1.3 出生体重

サンディエゴ（カリフォルニア州）の私立病院において、ある 1 週間の間に生まれた出生児の出生体重（g）の標本

i	x_i	i	x_i	i	x_i	i	x_i
1	3265	6	3323	11	2581	16	2759
2	3260	7	3649	12	2841	17	3248
3	3245	8	3200	13	3609	18	3314
4	3484	9	3031	14	2838	19	3101
5	4146	10	2069	15	3541	20	2834

当該標本における出生体重の算術平均を求めよ。

定義 1.2 中央値

標本に n 個の観測値があるとする。これらの観測値を小さい順に並べたとき、中央値は次のように定義される。

- ・ n が奇数のとき：中央の位置にある観測値 ($\frac{n+1}{2}$ 番目の観測値)
- ・ n が偶数のとき：中央の 2 つの観測値の平均 ($\frac{n}{2}$ 番目と $\frac{n}{2} + 1$ 番目の観測値の平均)

例 1.4 白血球数

ある特定の日にペンシルベニア州アレントアウンのある小規模病院に入院した全患者の、入院時の白血球数


Sample of admission white-blood counts
($\times 1000$) for all patients entering a hospital
in Allentown, Pennsylvania, on a given day

i	x_i	i	x_i
1	7	6	3
2	35	7	10
3	5	8	12
4	9	9	8
5	8		


この白血球数の中央値を求めよ。

- ・ 分布が対称の場合：中央値の両側にある点是对称的な位置をとる
 - ・ 例：工場労働者（30～39 歳）の収縮期血圧（図 2.3a）
- ・ 分布が正に歪む（右に歪む）場合：中央値より上の点は下の点より遠ざかる傾向
 - ・ 例：20～29 歳女性の経口避妊薬（OC）使用年数（図 2.3b）
- ・ 分布が負に歪む（左に歪む）場合：中央値より下の点は上の点より遠ざかる傾向
 - ・ 例：湿潤気候での相対湿度（図 2.3c）
- ・ 算術平均と中央値の関係は分布の対称性を示す
 - ・ 対称分布：算術平均 $\approx$ 中央値
 - ・ 正に歪む分布：算術平均 $>$ 中央値
 - ・ 負に歪む分布：算術平均 $<$ 中央値


Figure 2.3 Graphic displays of (a) symmetric, (b) positively skewed, and (c) negatively skewed distributions



(a)



(b)



(c)

定義 1.3 最頻値

最頻値とは、標本の中で最も頻繁に出現する値のことである。

モードの数による分布の分類

- ・ 分布には、複数のモードを持つ場合がある
- ・ 分布を分類する便利な方法の一つは、モードの数で分類すること
- ・ モードが1つ：単峰性 (unimodal)
- ・ モードが2つ：二峰性 (bimodal)
- ・ モードが3つ：三峰性 (trimodal)
- ・ さらに多い場合は「多峰性 (multimodal)」と呼ばれる

例 1.5 白血球数

ある特定の日にペンシルベニア州アレントアウンのある小規模病院に入院した全患者の、入院時の白血球数

Sample of admission white-blood counts
($\times 1000$) for all patients entering a hospital
in Allentown, Pennsylvania, on a given day

i	x_i	i	x_i
1	7	6	3
2	35	7	10
3	5	8	12
4	9	9	8
5	8		

この白血球数の最頻値を求めよ。

定義 1.4 幾何平均

幾何平均 GM は各データの対数をとった値の「算術平均」を求め、それを指数関数で元のスケールに戻す（逆対数をとる）ことで算出される。

$$GM = \exp\left(\frac{1}{n} \sum_{i=1}^n \log x_i\right)$$

- ・ 比率や割合データに適している
- ・ 算術平均よりも極端な値（外れ値）の影響を受けにくい
- ・ $n = 2$ の場合、幾何平均は $\sqrt{x_1 \cdot x_2}$
- ・ 例：成長率やリスク比の平均を求める際に使用される

例 1.6 MIC

74 人の患者における淋菌 (*N. gonorrhoeae*) に対する尿中ペニシリン G の最小発育阻止濃度 (MIC)

Distribution of minimum inhibitory concentration (MIC) of penicillin G for *N. gonorrhoeae*

Concentration ($\mu\text{g/mL}$)	Frequency	Concentration ($\mu\text{g/mL}$)	Frequency
$0.03125 = 2^0(0.03125)$	21	$0.250 = 2^3(0.03125)$	19
$0.0625 = 2^1(0.03125)$	6	$0.50 = 2^4(0.03125)$	17
$0.125 = 2^2(0.03125)$	8	$1.0 = 2^5(0.03125)$	3

Source: Based on *JAMA*, 220, 205–208, 1972.

幾何平均を求めよ。

標本点 $x_1, \dots, x_n$ を考える

定理 1.1

$$y_i = x_i + c, \quad (i = 1, \dots, n) \Rightarrow \bar{y} = \bar{x} + c$$

$$y_i = cx_i \Rightarrow \bar{y} = c\bar{x}$$

$$y_i = c_1x_i + c_2 \Rightarrow \bar{y} = c_1\bar{x} + c_2$$

例 1.7 出生体重

サンディエゴ（カリフォルニア州）の私立病院において、ある 1 週間の間に生まれた出生児の出生体重（g）の標本


i	x_i	i	x_i	i	x_i	i	x_i
1	3265	6	3323	11	2581	16	2759
2	3260	7	3649	12	2841	17	3248
3	3245	8	3200	13	3609	18	3314
4	3484	9	3031	14	2838	19	3101
5	4146	10	2069	15	3541	20	2834

当該標本における出生体重の算術平均（オンス）を求めよ。1 oz = 28.35 g

ばらつきの尺度

- ・ 同一人物のコレステロール値を異なる測定法で比較した2つの標本
- ・ 中心的位置の尺度はほぼ同一（平均値：200 mg/dL）

Figure 2.4 Two samples of cholesterol measurements on a given person using the Autoanalyzer and Microenzymatic measurement methods



マイクロ酵素法（Microenzymatic method）と比較して、オートアナライザー法（Autoanalyzer method）の方がばらつき（変動性、あるいはデータの広がり）が大きい

定義 1.5 範囲

範囲とは、標本における最大の観測値と最小の観測値の差である。

$$\text{Range} = \max(x_i) - \min(x_i)$$

- ・ 長所：標本の観測値を並べ替えれば、計算が非常に簡単
- ・ 短所：外れ値（極端な観測値）の影響を非常に受けやすい

定義 1.6 第 p 百分位数

p 番目の百分位数 (p th percentile) は次のように定義される：

1. $np/100$ が整数でない場合： $k = \lfloor np/100 \rfloor$ とすると、 $(k + 1)$ 番目に大きい観測値
2. $np/100$ が整数の場合： $(np/100)$ 番目と $(np/100 + 1)$ 番目に大きい観測値の平均

百分位数は、分位点 (quantile) と呼ばれることもある。

$k = \lfloor np/100 \rfloor$: $np/100$ 以下の最大の整数 (小数点以下を切り捨てた整数)

例 1.8 出生体重

サンディエゴ（カリフォルニア州）の私立病院において、ある 1 週間の間に生まれた出生児の出生体重（g）の標本

i	x_i	i	x_i	i	x_i	i	x_i
1	3265	6	3323	11	2581	16	2759
2	3260	7	3649	12	2841	17	3248
3	3245	8	3200	13	3609	18	3314
4	3484	9	3031	14	2838	19	3101
5	4146	10	2069	15	3541	20	2834

当該標本における第 10、90 百分位数を求めよ。

定義 1.7 分散と標準偏差

標本分散 (sample variance) は次のように定義される：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

標本標準偏差 (sample standard deviation) は、標本分散の平方根として定義される：

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$


すなわち、

$$s = \sqrt{s^2}$$

ここで s^2 は標本分散を表す。

例 1.9

Figure 2.4 Two samples of cholesterol measurements on a given person using the Autoanalyzer and Microenzymatic measurement methods



オートアナライザー法 (Autoanalyzer method) およびマイクロ酵素法 (Microenzymatic method) のデータについて、分散 (Variance) と標準偏差 (Standard Deviation) を算出せよ。

定理 1.2 標本分散の平行移動不変性

2つの標本

$$x_1, \dots, x_n \quad \text{と} \quad y_1, \dots, y_n$$

があり、ここで

$$y_i = x_i + c, \quad i = 1, \dots, n$$

とする。

それぞれの標本分散を s_x^2 と s_y^2 とすると、次の関係が成り立つ：

$$s_y^2 = s_x^2$$

すなわち、分散は定数の加算によって変化しない。

$$y_i = cx_i, \quad i = 1, \dots, n, \quad c > 0$$

であれば、

$$s_y^2 = c^2 s_x^2$$

$$s_y = cs_x$$

例 1.10 出生体重

サンディエゴ（カリフォルニア州）の私立病院において、ある 1 週間の間に生まれた出生児の出生体重（g）の標本

i	x_i	i	x_i	i	x_i	i	x_i
1	3265	6	3323	11	2581	16	2759
2	3260	7	3649	12	2841	17	3248
3	3245	8	3200	13	3609	18	3314
4	3484	9	3031	14	2838	19	3101
5	4146	10	2069	15	3541	20	2834

当該標本における出生体重の分散と標準偏差（オンス）を求めよ。1 oz = 28.35 g

算術平均と標準偏差を関連づけて考えることは有用

例えば、標準偏差が 10 であっても、算術平均が 10 の場合と 1000 の場合とでは、概念的な意味は異なる。

このような場合に用いられる特別な尺度が変動係数（Coefficient of Variation, CV）である。

定義 1.8 変動係数（Coefficient of Variation）

変動係数（CV）は、標本標準偏差と算術平均の比で定義される：

$$CV = 100\% \times \frac{s}{\bar{x}}$$

ここで

- ・ s は標本標準偏差
- ・ $\bar{x}$ は算術平均

CV が大きい場合は、「平均に対してばらつきがかなり大きい」状態を意味します。

例 1.11 出生体重

サンディエゴ（カリフォルニア州）の私立病院において、ある 1 週間の間に生まれた出生児の出生体重（g）の標本

i	x_i	i	x_i	i	x_i	i	x_i
1	3265	6	3323	11	2581	16	2759
2	3260	7	3649	12	2841	17	3248
3	3245	8	3200	13	3609	18	3314
4	3484	9	3031	14	2838	19	3101
5	4146	10	2069	15	3541	20	2834

当該標本における変動係数を求めよ。

標本のサイズが大きすぎて、すべての生データを表示することが困難な場合

定義 1.9 頻度

頻度分布 (Frequency distribution) とは、データセットに含まれる各値と、その頻度 (Frequency: その値がデータセット内に出現する回数) を順に並べて表示したもの

General layout of grouped data

Group interval	Frequency
$y_1 \leq x < y_2$	f_1
$y_2 \leq x < y_3$	f_2
.	.
.	.
.	.
$y_i \leq x < y_{i+1}$	f_i
.	.
.	.
.	.
$y_k \leq x < y_{k+1}$	f_k

- ・ グラフ表示の主な目的は、データセットの全体像を迅速に把握する
- ・ 統計量などの数値指標のみでは抽出が困難な情報を、視覚化によって直感的に理解しやすくする役割を担っている。

棒グラフ (Bar Plot)

棒グラフは、グループ化されたデータを表示する最も広く用いられる方法の一つ。作成手順は次の通り：

1. データの分類: データを相互に排他的な複数のグループ（カテゴリー）に分類する
2. 長方形（棒）の描画: 各グループに対応する垂直または水平の長方形を作成する
3. 一定の幅: 視覚的な誤解を避けるため、すべての棒の幅（底辺）は一定にする
4. 高さと度数: 棒の高さ（または長さ）を、各グループの度数（出現回数）や相対度数に比例させる
5. 配置: 各グループが独立していることを示すため、棒の間には通常、一定の間隔を設けて配置する

茎葉図

1. 各データの数値を「茎 (Stem)」と「葉 (Leaf)」に分割する
 茎 = 右端の桁 (通常は一の位) を除いた上位の数字
 葉 = 右端の桁の数字
2. データ内の最小の茎を、図の左上部に配置する
3. 最小の茎から最大の茎まで、1 単位ずつ増やしながら垂直に並べる
4. 最大の茎に到達するまで繰り返す
5. 茎の列のすぐ右側に垂直な境界線を引く
6. 各データについて、該当する茎の右側にその「葉」の数字を記入していく

Figure 2.8 Stem-and-leaf and box plots for the birthw by the SAS UNIVARIATE procedure




Table 2.7 Sample of birthweights (oz) from 100 consecutive deliveries at a Boston hospital


58	118	92	108	132	32	140	138	96	161
120	86	115	118	95	83	112	128	127	124
123	134	94	67	124	155	105	100	112	141
104	132	98	146	132	93	85	94	116	113
121	68	107	122	126	88	89	108	115	85
111	121	124	104	125	102	122	137	110	101
91	122	138	99	115	104	98	89	119	109
104	115	138	106	144	87	88	103	108	109
128	106	125	108	98	133	104	122	124	110
133	115	127	135	89	121	112	135	115	64

箱ひげ図

箱ひげ図は、中央値、上四分位数、下四分位数の関係を用いて分布の歪み (skewness) を表現する方法

- ・ 第 1 四分位数 (Q_1 / 下四分位数) : データを昇順に並べた際の第 25 百分位点 (下位から $1/4$ の位置) に相当する。
- ・ 第 3 四分位数 (Q_3 / 上四分位数) : データを昇順に並べた際の第 75 百分位点 (下位から $3/4$ の位置) に相当する。

Figure 2.8 Stem-and-leaf and box plots for the birthweight data (oz) in Table 2.7 as generated by the SAS UNIVARIATE procedure



箱ひげ図から「歪み」を読み取るポイント

箱（四分位範囲）の中にある「中央値の線」の位置を見ることで、分布の形状を判断できます。

1. 左右/上下対称な分布: 中央値の線が箱のちょうど真ん中にあり、上下（左右）のひげの長さがほぼ等しい。
2. 正の歪み（右に裾を引く分布 / Positive Skew）：中央値が箱の下方に寄っており、上側のひげが下側よりも長くなる傾向がある。
3. 負の歪み（左に裾を引く分布 / Negative Skew）：中央値が箱の上方に寄っており、下側のひげが上側よりも長くなる傾向がある。

IQR（四分位範囲）：箱の長さ（ $Q_3 - Q_1$ ）は、データの中央 50%がどの程度の範囲に密集しているかを示します。

定義 1.10 外れ値

外れ値（Outlying value / Outlier）とは、以下のいずれかの条件を満たす値 x のことを指す。

- ・ $x > \text{上四分位数} + 1.5 \times (\text{上四分位数} - \text{下四分位数})$
- ・ $x < \text{下四分位数} - 1.5 \times (\text{上四分位数} - \text{下四分位数})$

極端な外れ値（Extreme outlying value）とは

- ・ $x > \text{上四分位数} + 3 \times (\text{上四分位数} - \text{下四分位数})$
- ・ $x < \text{下四分位数} - 3 \times (\text{上四分位数} - \text{下四分位数})$