

1D733 統計推測特論

3. 離散確率分布

April 27, 2026

数理環境論 Room 742

Email: ZHOU YI <zhouy@people.kobe-u.ac.jp>

異なる種類の事象であっても、同じ確率構造で扱うことができる。この目的のために、確率変数の概念を導入する。

Def 3.1 確率変数

確率変数とは、標本空間の各事象に数値を対応させる関数

- ・ **離散確率変数**: 取りうる値が離散的（有限または可算無限）である確率変数
- ・ **連続確率変数**: 取りうる値を個別に列挙できない確率変数

Ex 3.2 中耳炎

中耳炎は中耳の病気とする。生後 2 年間に於いて、定期的な健診以外で医師の診察を受ける最も一般的な理由の一つとする。

生後 2 年間に於ける中耳炎の発症回数を表す確率変数を X とする。

X は離散確率変数であり、 $0, 1, 2, \dots$ の値をとる。

Ex 3.3 放射線被曝量

長期間にわたる低線量放射線被曝が労働者に及ぼす健康影響は、公衆衛生上の関心事とする。この問題を評価する上での課題の一つは、労働者の累積被曝量をどのように測定するかとする。

ポーツマス海軍造船所で行われた研究では、被曝した労働者はそれぞれバッジまたは線量計を装着し、年間の放射線被曝量をレム単位で測定する。そして、年間の被曝量を合計することで、労働者の生涯にわたる累積被曝量を求めることができるとする。

生涯累積被曝量は、この研究では 0.000 レムから 91.414 レムまで変化するため、連続確率変数の例とする。これは本質的に無限の値をとると考えられ、列挙することはできないとする。

離散確率変数の確率質量関数

Def 3.4 確率質量関数 (probability mass function, PMF)

確率質量関数とは、離散型確率変数 X のとりうる値 r に対して、その値をとる確率 $P(X = r)$ を対応させる数学的な関数

この対応は、確率が正の値をとるすべての r に対して定義する。

確率質量関数は「確率関数」とも呼ぶ。

Ex 3.5 血圧薬

ある薬に関して過去の経験から、製薬会社は次のように予想する。

どの臨床現場においても、4 人の患者のうち、0 人の血圧がコントロールされる確率は 0.008、1 人の場合は 0.076、2 人の場合は 0.265、3 人の場合は 0.411、4 人すべてがコントロールされる確率は 0.240 とする。

この確率質量関数（または確率分布）は、以下の表に示す。

r	0	1	2	3	4
$P(X = r)$	0.008	0.076	0.265	0.411	0.240


標本における**頻度分布** (frequency distribution) とは、データ集合の各値と、その値が出現する回数 (度数) を対応させた一覧
各頻度を標本の全データ数で割ることで、頻度分布は確率分布の標本版とみなすことができる。

確率分布 (probability distribution) とは、無限に大きい標本を仮定したモデルと考えることができ、各特定の値に割り当てられるデータの割合を示すもの

Comparison of the sample-frequency distribution and the theoretical-probability distribution for the hypertension-control example

Number of hypertensives under control = r	Probability distribution $Pr(X = r)$	Frequency distribution
0	.008	.000 = 0/100
1	.076	.090 = 9/100
2	.265	.240 = 24/100
3	.411	.480 = 48/100
4	.240	.190 = 19/100

Comparison of the frequency and probability distribution for the hypertension-control example



Def 3.6 離散型確率変数の期待値

離散型確率変数の期待値 (expected value) は、次のように定義する。

$$E(X) \equiv \mu = \sum_{i=1}^R x_i P(X = x_i)$$

ここで、 x_i は確率変数の実現値とする。

Ex 3.7 血圧薬

$$E(X) = 0(0.008) + 1(0.076) + 2(0.265) + 3(0.411) + 4(0.240) = 2.80$$

したがって、平均すると、治療を受けた 4 人のうち約 2.8 人の高血圧患者がコントロールされると予想する。

Def 3.8 離散型確率変数の分散

離散型確率変数の分散 (variance) は $\text{Var}(X)$ と表し、次のように定義する。

$$\text{Var}(X) = \sigma^2 = \sum_{i=1}^R (x_i - \mu)^2 P(X = x_i)$$

ここで、 x_i は確率変数の実現値とする。

また、確率変数 X の標準偏差 (standard deviation) は $\text{sd}(X)$ または σ と表し、分散の平方根として定義する。

$$\sigma = \sqrt{\text{Var}(X)}$$

母分散 (population variance) は次のように表す。

$$\sigma^2 = E(X^2) - [E(X)]^2 = \sum_{i=1}^R x_i^2 P(X = x_i) - \mu^2$$

ここで、 $E(X^2)$ は確率変数の二乗の期待値、 $E(X)$ はその期待値とする。

Ex 3.9 血圧薬

分散はと標準偏差を求めよ

Def 3.10 累積分布関数 (cumulative-distribution function, cdf)

確率変数 X の累積分布関数は $F(x)$ と表し、特定の値 x に対して次のように定義する。


$$F(x) = P(X \leq x)$$

すなわち、確率変数 X が値 x 以下をとる確率とする。

離散型確率変数の場合、累積分布関数 (cdf) は階段状の形をとり、ステップ関数 (step function) と呼ぶ。

Ex 3.11 中耳炎

生後 2 年間における中耳炎の発症回数を表す確率変数を考える。この確率変数は、以下の表に示す確率質量関数をもつとする。



順列 (permutations) と組合せ (combinations)

Def 3.12 順列

n 個のものから k 個を取り出す順列の数は、次のように表す。

$${}_nP_k = n(n-1)\cdots(n-k+1)$$

これは、 n 個の中から k 個を選ぶ方法の数を表し、選ぶ順序を区別する場合とする。

Ex 3.13 統合失調症

同一の地域に、50～59 歳の統合失調症の女性が 3 人おり、適格な対照が 6 人いるとする。

このとき、対照から 3 人を選ぶ方法は何通りあるかを求める。

$${}_nP_n = n(n-1)\cdots[n-(n-1)] = n(n-1)\cdots 2\cdot 1$$

$$n \text{ の階乗: } n! = n(n-1)\cdots 2\cdot 1$$

$${}_nP_k = \frac{n!}{(n-k)!}$$

Def 3.14 組合せ

n 個のものから k 個を取り出す組合せの数は、次のように表す。

$${}_nC_k = \binom{n}{k} = \frac{n(n-1)\cdots(n-k+1)}{k!}$$

$${}_nC_k = \binom{n}{k} = \frac{{}_nP_k}{k!} = \frac{n!}{k!(n-k)!}$$

$$\binom{n}{k} = \binom{n}{n-k}$$

二項分布 (binomial distribution) に関するすべての例は共通の構造をもつ。

すなわち、 n 回の独立な試行からなる標本とし、各試行は「成功 (success)」または「失敗 (failure)」のいずれか一方のみが起こるとする。

さらに、各試行における成功の確率は一定の値 p とし、失敗の確率は $1 - p = q$ とする。

ここで「成功」という用語は、特定の文脈に依存しない一般的な意味で用いる。

Ex 3.15 好中球

好中球を x、非好中球を o とする。次のような結果が得られる確率を求める。

$$P(\text{oxoox})$$

成功（好中球）の確率を $p = 0.6$ 、失敗（非好中球）の確率を $q = 0.4$ とし、各細胞の結果は互いに独立とする。したがって、この結果の確率は次のように表す。

$$q \times p \times q \times q \times p = p^2 q^3 = (0.6)^2 (0.4)^3$$

Ex 3.16 好中球

5 個の細胞のうち、ちょうど 2 個が好中球である確率を求める。この確率は二項分布に従い、次のように表す。

$$P(X = 2) = \binom{5}{2} p^2 q^3$$

ここで、 p は好中球である確率、 $q = 1 - p$ は非好中球である確率とする。
 $p = 0.6$, $q = 0.4$ のとき、

$$P(X = 2) = \binom{5}{2} (0.6)^2 (0.4)^3 = 10 \times 0.36 \times 0.064 = 0.2304$$

したがって、5 個のうち 2 個が好中球である確率は約 0.23 とする。

Possible orderings for 2 neutrophils of 5 cells

XXOOO	OXXOO	OOXOX
XOXOO	OXOXO	OOOXX
XOOXO	OXOOX	
XOOOX	OXXOX	

Def 3.17 二項分布

n 回の統計的に独立な試行において、各試行で成功する確率を p とする。このとき、成功回数の分布を二項分布 (binomial distribution) と呼ぶ。その確率質量関数は次のように表す。

$$P(X = k) = \binom{n}{k} p^k q^{n-k}, \quad k = 0, 1, \dots, n$$

ここで、 $q = 1 - p$ は失敗の確率とする。

$$Pr(X = k) = \binom{n}{k} p^k q^{n-k} = \binom{n}{n-k} q^{n-k} p^k = Pr(Y = n - k)$$

二項分布の期待値と分散

二項分布に従う確率変数 $X \sim \text{Bin}(n, p)$ の期待値と分散は次のように与える。

$$E(X) = np$$

$$\text{Var}(X) = npq = np(1 - p)$$

ここで、 n は試行回数、 p は成功の確率、 $q = 1 - p$ は失敗の確率とする。

この分布は通常、まれな事象（rare events）に関連する。

Def 3.18 ポアソン分布（Poisson）

ポアソン確率変数において、時間区間 t の間に k 回の事象が発生する確率は次のように表す。

$$P(X = k) = \frac{e^{-\mu} \mu^k}{k!}, \quad k = 0, 1, 2, \dots$$

ここで、 $\mu = \lambda t$ とし、 e は自然対数の底とする。

Ex 3.19 腸チフス

長期間（1 年間など）における腸チフスによる死亡者数の分布を考える。
任意の 1 日における新たな腸チフス死亡の確率は非常に小さく、異なる期間に報告される症例数は互いに独立とする。
このとき、1 年間の死亡者数はポアソン分布に従うとする。

時間 0 から時間 t (例えば 1 年や 20 年などの長期間) までの腸チフスによる死亡者数の分布を考える。

この疾病の発生について、次の 3 つの仮定を置く。時間区間 t の小さな部分区間を Δt とする。

Thm 3.20 仮定 4.1

(1) 1 件の死亡が観測される確率は、時間区間の長さ Δt に比例するとする。
すなわち、ある定数 λ に対して

$$P(1 \text{ death}) \approx \lambda \Delta t$$

(2) 区間 Δt の間に死亡がまったく起こらない確率は次のように表す。

$$P(0 \text{ deaths}) \approx 1 - \lambda \Delta t$$

(3) この時間区間に 2 件以上の死亡が起こる確率は、ほぼ 0 とする。

Thm 3.21 仮定 4.2 定常性 (Stationarity)

単位時間あたりの死亡者数は、期間 t の全体を通じて一定と仮定する。

したがって、期間中に疾病の発生率が時間とともに増加する場合、この仮定は成り立たないとする。また、 t が非常に長い場合、この仮定は成立しにくいとする。

Thm 3.22 仮定 4.3 独立性 (Independence)

ある時間区間で死亡が起こっても、次の時間区間における死亡の確率には影響を与えないと仮定する。

この仮定は、流行 (epidemic) が起こる状況では成り立たないとする。

新たな感染が発生すると短期間に死亡者数が増加し、その影響が流行の収束まで続く可能性がある。

ポアソン分布は1つのパラメータ $\mu = \lambda t$ によって定まる。 λ は単位時間あたりの事象の期待回数を表し、 μ は時間区間 t 全体における事象の期待回数を表す。

Ex 3.23 腸チフス

腸チフスの例を考える。

1 年間の腸チフスによる死亡者数は平均 $\mu = 4.6$ のポアソン分布に従うとする。6 か月間および 3 か月間における死亡者数の確率分布を求める。

Ex 3.24

まず、 X を 6 か月間の死亡者数とする。 $\mu = 4.6$ 、 $t = 1$ 年より、単位時間あたりの発生率は $\lambda = 4.6$ (件/年) とする。

6 か月 ($t = 0.5$ 年) の場合：

$$\mu = \lambda t = 4.6 \times 0.5 = 2.3$$

したがって、 $X \sim \text{Poisson}(2.3)$ です。

$$Pr(X = 0) = e^{-2.3} \frac{2.3^0}{0!} = 0.100$$

$$Pr(X = 1) = e^{-2.3} \frac{2.3^1}{1!} = 0.231$$

...

$$Pr(X = 5) = e^{-2.3} \frac{2.3^5}{5!} = 0.054$$

したがって、6 か月間に 6 件以上の死亡が起こる確率は

$$Pr(X \geq 6) = 1 - (0.100 + 0.231 + 0.265 + 0.203 + 0.117 + 0.054) = 0.030$$

Ex 3.25

次に、 Y を 3 か月間の死亡者数とする。

3 か月 ($t = 0.25$ 年) の場合：

$$\mu = \lambda t = 4.6 \times 0.25 = 1.15$$

したがって、 $Y \sim \text{Poisson}(1.15)$ とする。

$$P(Y = 0) = e^{-1.15} \frac{1.15^0}{0!} = 0.317$$

$$P(Y = 1) = e^{-1.15} \frac{1.15^1}{1!} = 0.364$$

$$P(Y = 2) = e^{-1.15} \frac{1.15^2}{2!} = 0.209$$

$$P(Y = 3) = e^{-1.15} \frac{1.15^3}{3!} = 0.080$$

したがって、3 か月間に 4 件以上の死亡が起こる確率は次のように表す。

$$P(Y \geq 4) = 1 - (0.317 + 0.364 + 0.209 + 0.080) = 0.030$$

二項分布のポアソン近似

Thm 3.26 二項分布のポアソン近似

二項分布 $\text{Bin}(n, p)$ において、試行回数 n が大きく、成功確率 p が小さい場合 (例: $n \geq 20, p \leq 0.05$)、平均 $\mu = np$ を一定とすると、この分布はポアソン分布で近似できる。


$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k} \approx \frac{e^{-\mu} \mu^k}{k!}$$

ここで、 $\mu = np$ は期待される成功回数とする。


ポアソン分布と二項分布の重要な違いの1つは、試行回数と事象数に関する性質とする。

- ・ 二項分布では、試行回数 n は有限とし、発生する事象の数 (成功回数) は n を超えないとする。
- ・ ポアソン分布では、試行回数は実質的に無限とし、発生する事象数も理論上は無限に大きくなり得るとする。ただし、事象の回数 k が大きくなるにつれて、その確率 $P(X = k)$ は非常に小さくなるとする。


FIGURE 4.5 The binomial distribution for various values of p when $n = 10$



(a) $n = 10, p = .05$




(b) $n = 10, p = .95$




(c) $n = 10, p = .50$

FIGURE 4.6 Distribution of the number of deaths attributable to typhoid fever over various time intervals



(a) 6 months



(b) 3 months